



COLEGIO DE POSTGRADUADOS
INSTITUCIÓN DE ENSEÑANZA E INVESTIGACIÓN EN CIENCIAS
AGRÍCOLAS
MÉXICO-PUEBLA-SAN LUIS POTOSÍ-TABASCO-VERACRUZ-CÓRDOBA
CAMPUS MONTECILLO



POSGRADO EN SOCIOECONOMÍA, ESTADÍSTICA E
INFORMÁTICA
CÓMPUTO APLICADO (PSEI-COA)

CURSO: COA-615 VISIÓN ARTIFICIAL APLICADA A LOS
RECURSOS NATURALES: AGUA, SUELO Y VEGETACIÓN

PROFESORA: DRA. ANTONIA MACEDO CRUZ

PROYECTO FINAL: CLASIFICACIÓN SUPERVISADA DE IMÁGENES DE
RADAR DE APERTURA SINTÉTICA PARA DETERMINAR ZONAS INUNDADAS
EN EL ESTADO DE TABASCO.

ALUMNO: JUAN PABLO AMBROSIO AMBROSIO

A 17 DE AGOSTO DEL 2020

Tabla de contenido

INTRODUCCIÓN	4
PLANTEAMIENTO DEL PROBLEMA	4
ALCANCES	6
OBJETIVOS	6
GENERAL.....	6
PARTICULAR	6
ZONA DE ESTUDIO	6
METODOLOGÍA	7
DATOS DE ENTRADA	7
PREPROCESAMIENTO DE IMÁGENES DE APERTURA SINTÉTICA	8
SELECCIÓN DE MUESTRAS.....	9
SEGMENTACIÓN Y EXTRACCIÓN DE CARACTERÍSTICAS	10
CLASIFICACIÓN Y VALIDACIÓN DEL MODELO	11
RESULTADOS	11
PREPROCESAMIENTO DE IMÁGENES DE APERTURA SINTÉTICA	11
SELECCIÓN DE MUESTRAS.....	13
SEGMENTACIÓN Y EXTRACCIÓN DE CARACTERÍSTICAS	16
CLASIFICACIÓN Y VALIDACIÓN DEL MODELO	17
MATRIZ DE CONFUSIÓN	18
PREDICCIÓN.....	22
CONCLUSIÓN	23
BIBLIOGRAFÍA	24

ÍNDICE DE FIGURAS

Figura 1. Zona de estudio.	7
Figura 2. Vista previa de la imagen SAR adquirida.	8
Figura 3. Flujo de trabajo en el procesamiento de imágenes SAR. Fuente: elaboración propia.	9
Figura 4. Proceso de segmentación y extracción características de interés.....	10
Figura 5. Imagen original SAR.	11
Figura 6. Imagen SAR Calibrada y Recortada.	12
Figura 7. Corrección del moteado de la imagen SAR.....	12
Figura 8. Imagen SAR corregida.....	13
Figura 9. Vista de la imagen SAR en combinación RGB.....	13
Figura 10. Imagen de muestra que representa un río.	14
Figura 11. Muestra de un río sobre la imagen SAR.	14
Figura 12. Imagen de muestra para la clase tierra.	14
Figura 13. Muestra de la clase tierra sobre la imagen SAR.....	15
Figura 14. Muestra de la clase urbano.	15
Figura 15. Muestra de la clase urbano sobre la imagen SAR.....	15
Figura 16. Segmentación por el método Crecimiento por Región.	16
Figura 17. Método del codo para determinar el número óptimo de clúster.	16
Figura 18. Ventana de configuración de la intersección.	17
Figura 19. Exportación de características de los pixeles de interés a un archivo csv.	17
Figura 20. Calculo de índices en una matriz de confusión multiclase.....	19
Figura 21. Matriz de confusión para el modelo SVM Gaussian Fine.	20
Figura 22. Ejemplo de clasificación del modelo SVM Gaussian entrenado.	22

INTRODUCCIÓN

La clasificación de imágenes se puede definir como el proceso que busca identificar la clase a la que pertenece cada pixel, objeto o región dentro una imagen. La clasificación puede ser supervisada consiste en que se utilizan datos (firmas espectrales) ya identificados como muestras para encontrar datos no identificados. La no supervisada busca datos en una imagen sin datos de muestra es decir sin la ayuda de un experto o un estudio previo de la imagen. Avendaño et al. (2014) propusieron una metodología para llevar a cabo una clasificación multiclase (Agua, Tierra y Población), obteniendo resultados muy aceptables. Los clasificadores que evaluaron fueron la máquina de soporte vectorial (SVM) y el modelo Bayesiano. El rendimiento del modelo SVM fue superior al bayesiano, aunque este último tiene un buen rendimiento cuando se emplean conjunto de datos pequeños de entrenamiento, de tal manera que se produce un modelo bastante robusto.

La segmentación busca extraer características de las imágenes como, por ejemplo: puntos de interés, bordes, contornos, regiones, etc. Este proceso divide la imagen en grupos de pixeles u objetos dando como resultado un conjunto de segmentos que cubren la imagen, o un conjunto de curvas de nivel extraídas de la imagen (Das et al., 2012). El método de crecimiento por región fue desarrollado por Adamas and Bischof en 1994 y busca por medio de un criterio de similitud agrupar pixeles. El proceso empieza con unos valores de intensidad de pixel dentro de la imagen que son definidos inicialmente, a estos valores se les conoce como semillas.

El método K-medias fue desarrollado por MacQueen en 1967. Es uno de los métodos no supervisados para agrupar Clúster. Su funcionamiento consiste en escoger en primera instancia k-centroides de cada elemento a agrupar, la colocación de estos centroides juega un papel importante a la hora de tener una buena agrupación. Después de que se han colocado los centroides se procede a calcular la distancia de cada elemento a cada centroide, etiquetando el elemento con el centroide con el cual tiene menor distancia de separación. Una vez se han asignado las etiquetas a todos los elementos se encuentra nuevamente la ubicación de cada centroide calculando la media de los valores asignados al grupo del centroide. Ghosh y Kumar (2013) llevaron a cabo una comparación entre el algoritmo k-medias y el algoritmo difuso C-medias sobre la base de dato iris obteniendo resultados muy similares para los dos modelos, aunque el algoritmo k-medias es computacionalmente mucho más rápido.

PLANTEAMIENTO DEL PROBLEMA

En la actualidad ya es completamente una realidad la disposición de imágenes de satélite obtenidas mediante sensores remotos de radar de apertura sintética. En

comparación con los sensores ópticos, las imágenes de radar ya no dependen de la radiación solar reflejada o la radiación térmica emitida por la tierra para funcionar, sino que emiten su propia radiación electromagnética para realizar sondeos. Gracias a estas ondas electromagnéticas empleadas, en la tecnología radar no se ven afectadas por las nubes, la niebla y la lluvia, por lo que se puede adquirir imágenes independientemente de las condiciones meteorológicas.

La idea básica de emplear imágenes de satélite para atender una tarea específica normalmente surge ante la necesidad de abarcar grandes superficies o zonas de estudio que en muchas ocasiones presentan problemas de acceso, lo cual abstraer información sin estar en contacto directo se evalúa muy prometedor. La mayoría de las aplicaciones de las imágenes satelitales se reducen a una segmentación y clasificación, que en la actualidad se lleva a cabo con software de sistemas de información gráfica y software de productos satelitales específicos. La desventaja que presentan estos softwares es que por su naturaleza están desarrollados para un usuario final y para tareas específicas, esto finalmente se traduce en que los algoritmos que llevan a cabo la tarea no son visibles y sin posibilidad de modificación para obtener un mejor resultado.

Ante tales circunstancias surge la inquietud de desarrollar una aplicación capaz de segmentar una imagen de radar de apertura sintética (SAR) y posteriormente llevar a cabo una clasificación en función de la naturaleza del problema que se esté abordando. Tanto el proceso de segmentación como clasificación de una imagen son tareas muy complejas a tal grado que la efectividad de un método depende de muchos factores. Este hecho provoca que existan muchas alternativas para llegar a un mismo objetivo.

Es muy usual que, en los meses de agosto, septiembre y octubre se presenten intensas jornadas de lluvias en el sureste mexicano provocando en muchas ocasiones inundaciones de gran magnitud. Este tipo de desastre natural provoca pérdidas económicas en diferentes áreas, por ejemplo, en la construcción, ramo agrícola, ganadera y en ocasiones drásticamente cobra vidas humanas. Una de las tareas de gran importancia es la cuantificación de la superficie afectada por las inundaciones. Esta tarea se complica debido al acceso a las zonas afectadas y al tratarse de superficies amplias pensar en un recorrido de campo de toda la zona se traduce en un objetivo muy costoso y demasiado tardado.

Es por ello que surge la necesidad de plantear una metodología que implemente imágenes de satélite y las herramientas de visión artificial para clasificar zonas afectadas por inundaciones. En este proyecto específico se considera como zona de estudio el Estado de Tabasco, la inundación de interés es la ocurrida el día 8 de octubre de 2017.

ALCANCES

La metodología expuesta en este trabajo genera una propuesta de clasificación en tres clases, zona de inundada, tierra (que incluye vegetación y todo tipo de cubierta de suelo natural) y urbano (que incluye todas aquellas infraestructuras creadas por la humanidad). Es preciso mencionar que este proyecto es con fines académicos, es por ello que el muestreo de las clases se llevó a cabo de manera puntual auxiliado de imágenes de satélite híbrido proporcionado por google, para mayor asertividad se debe plantear un método de muestreo y recolectar información de campo. Por otra parte, para aumentar la velocidad de procesamiento se ejecutaron pruebas con imágenes recortadas, para un estudio más preciso es necesario incluir muestras de imagen más grandes que abarquen puntos específicos de interés, y tener la posibilidad de validar y compartir los resultados empleando un sistema de información geográfica.

OBJETIVOS

GENERAL

- Desarrollar una aplicación en MATLAB 2016^a que permite entrenar modelos de aprendizaje automático supervisado capaz de llevar a cabo una clasificación multiclase en donde interesa determinar áreas inundadas en imágenes de radar de apertura sintética.

PARTICULAR

- Pre procesamiento de imágenes de radar de apertura sintética empleando Sentinel Application Platform (SNAP).
- Extracción de muestras para cada clase de interés, empleando Quantum Gis 3.10 y la imagen de satélite híbrida proporcionada por Google.
- Desarrollar una aplicación en Matlab 2016^a que permite llevar a cabo segmentación de imágenes mediante: crecimiento de región, K-media y determinación manual del umbral.
- Implementar los algoritmos de clasificación disponibles en el software Matlab 2016^a, e implementar una interfaz gráfica que permite el entrenamiento, evaluación de la precisión y predicción de los modelos: Bagged Forest y Support Vector Machines (SVM) Gaussian Fine.

ZONA DE ESTUDIO

La zona de estudio se centra en el estado de Tabasco, ubicado en el sureste mexicano pegado al golfo de México. Entre los asentamientos urbanos destacan: Macuspana, Chilapilla, Bitzal, Jonutla, Tepetitán, Benito Juárez, Rivera alta, La frontera y Palizada, ver figura 1.




Figura 1. Zona de estudio.

METODOLOGÍA

DATOS DE ENTRADA

Se dispone de una imagen de apertura sintética obtenida de la página Alaska Satellite Facility disponible en: <https://asf.alaska.edu/>

Las características específicas de la imagen SAR adquirida son las siguientes, la vista previa se puede ver en la figura 2:

- Nombre del producto: S1A_IW_GRDH_1SDV_20171008T
- Fecha de toma: 8 de octubre de 2017 12:01:21
- Nivel de procesamiento: 1, producto estándar (georeferenciado)
- Modo de Haz (Beam Mode): IW Interferometric (5x20)
- Ancho de Barrido: 250 km
- Tipo de producto: Grand Range Deteccion (GRD)
- Polarización: 1SDV Dual VV+VH
- Frecuencia: Banda C
- Paso: Descendente




Figura 2. Vista previa de la imagen SAR adquirida.

PREPROCESAMIENTO DE IMÁGENES DE APERTURA SINTÉTICA

Debido a la naturaleza con la que son adquirida las imágenes de radar de apertura sintética (SAR) es completamente indispensable llevar a cabo un pre procesamiento de la imagen antes de poder ejecutar un análisis sobre ella. En la figura 3 se puede observar el flujo de trabajo para el pre procesamiento de la imagen. Todo este proceso se puede ejecutar con el software SNAP desarrollada para procesar imágenes de radar producidas por el satélite Sentinel de la estación geoespacial española y distribuida con licencia open source.

El primer paso consiste en definir una subsección de la imagen original esto con la finalidad de agilizar el proceso de corrección y va estar en función del área de interés y la potencia del equipo de cómputo con la que se tiene. Sobre la imagen de interés se lleva a cabo una primera corrección radiométrica mediante una calibración proporcionada por el software SNAP. Posteriormente se corrige uno de los detalles más visibles de la imagen SAR, que es el moteado. Este problema denominado en inglés como speckle se produce por una pérdida de información en el proceso de obtención de la imagen, para corregirlo se dispone de dos opciones. La primera hace referencia a un proceso de multilooking que consiste en hacer una interpolación de los datos disponibles, este efecto provoca una disminución en el detalle de la imagen ya que disminuye la escala para solapar aquellos pixeles que no tienen información. La ventaja de este método es que se preservan los valores de los pixeles originales. La otra opción que se tiene es ejecutar diferentes tipos de filtros, con diferentes máscaras y hacer un recorrido pixel por pixel para obtener información faltante. Se pueden probar las diferentes modalidades y elegir la que

arroje los mejores resultados. A continuación, sobre la imagen ya procesada se lleva a cabo una corrección geométrica, que consiste en ubicar la imagen con un sistema de georreferencia y facilitar su visualización posterior en cualquier software de sistema de información geográfica. Por último, se lleva a cabo la exportación de la imagen en el formato de conveniencia, en este proyecto específico se optó por el formato tif.

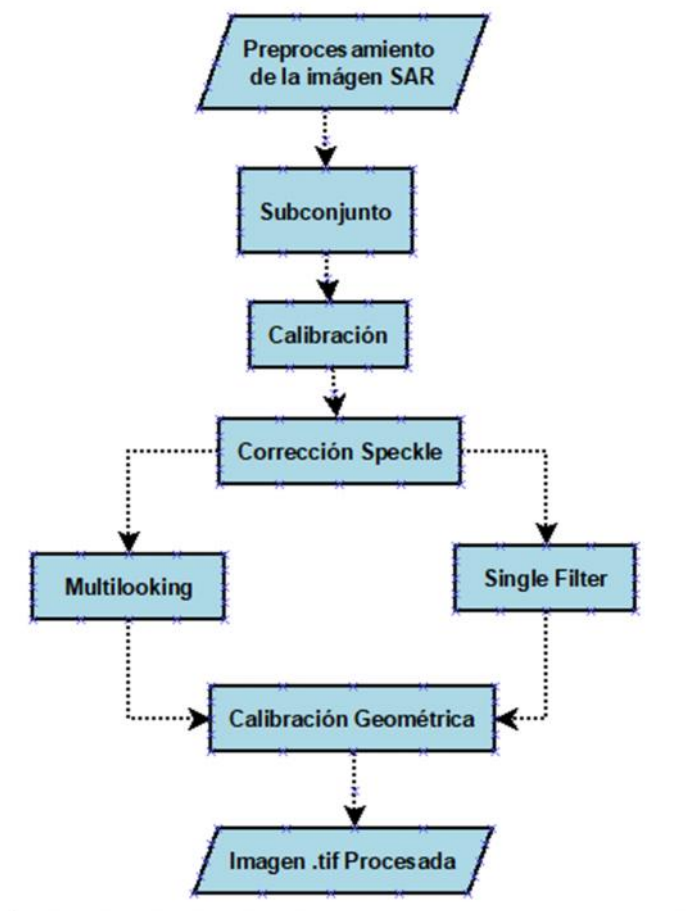


Figura 3. Flujo de trabajo en el procesamiento de imágenes SAR. Fuente: elaboración propia.

SELECCIÓN DE MUESTRAS

Debido a que es muy poco probable que alguna institución tenga una base de datos georreferenciados específicamente con las clases que se desea clasificar, se opta por generar una base de datos a partir de pequeñas muestras que resaltan las características a clasificar, por ejemplo: ríos, lagunas, pantanos, ciudades, carreteras, vegetación y suelo desnudo.

Se tiene la ventaja de que se están manejando como datos de entrada imágenes, y vistas a nivel pixel la cantidad de información disponible es considerable. Se propone una muestra por cada clase. Después del proceso de segmentación y extracción de características de interés, si el número de píxeles es mínimo

considerar la posibilidad de segmentar muestras adicionales. En resumen, se tienen 3 muestras para adquirir información de entrenamiento (una muestra por cada clase) y se obtienen tres muestras de interés con la que se desea probar el algoritmo (de preferencia que tenga las tres clases y valorar el comportamiento del clasificador). Se plantea una base de datos con 3000 muestras para cada clase, es decir 9000 muestras en total. Con el fin de observar el comportamiento de la precisión en el proceso de entrenamiento del modelo se propone ejecutar pruebas sobre particiones equivalentes a 500, 1000 y 3000 muestras por cada clase. Para cada proceso de entrenamiento se le aplica una validación cruzada integrada por cinco grupos ($k=5$ pliegos).

SEGMENTACIÓN Y EXTRACCIÓN DE CARACTERÍSTICAS

Se tiene como dato de entrada una imagen con formato tif y dos bandas, de tal manera que en primera instancia es necesario convertir la imagen en formato jpg. Se proponen tres métodos de segmentación; la primera consiste en el método de crecimiento por región misma que tiene como principal parámetro la semilla de arranque. Como segundo método se tiene K medias en la cual el principal parámetro es el número de centroides con la que se desea agrupar todos los pixeles de la imagen. Para la selección óptima del número de centroides se integra el método del codo. Como una tercera opción se tiene la definición manual del umbral, mediante la definición del límite superior e inferior. En función del resultado generado por cada método, se puede llevar a cabo una intersección de regiones o en su caso ejecutar una segmentación mediante un único método.

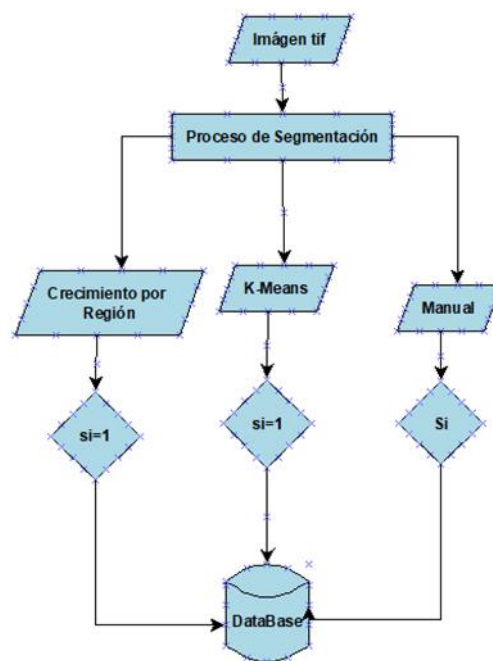


Figura 4. Proceso de segmentación y extracción características de interés.

CLASIFICACIÓN Y VALIDACIÓN DEL MODELO

Para el proceso de entrenamiento, se utilizan las muestras extraídas en el proceso de segmentación con las siguientes estructuras; se consideran como variables predictoras las intensidades de la imagen (banda rojo, verde y azul). Com variable respuesta se tiene las categorías; 1 agua, 2 tierra y 3 urbano.

Con la ayuda de la herramienta “Classification learner” de MATLAB se entrenan los modelos: SVM y BAGGED FOREST. Se considera la validación cruzada con cinco subgrupos para evitar problemas de sobre-ajuste. Con los modelos calibrados se exporta el código para su posterior parametrización mediante la interfaz gráfica para poder generar predicciones sobre muestras desconocidas al modelo.

RESULTADOS

PREPROCESAMIENTO DE IMÁGENES DE APERTURA SINTÉTICA

Todas las herramientas utilizadas en esta sección son de las que dispone el software SNAP. En la figura 5 se puede ver la imagen de apertura sintética original con formato “.zip” descargada de la página Alaska Satellite Facility. Se llevó a cabo la extracción de un subconjunto mediante la herramienta Raster>>Subset, el parámetro principal es el número de píxeles (x, y) de las dos esquinas que definen el rectángulo de interés.




Figura 5. Imagen original SAR.

Posteriormente sobre la imagen recortada se lleva a cabo una calibración mediante la herramienta Radar>>Radiometric>>Calibrate. En la figura 6, se puede observar la imagen recortada y calibrada.




Figura 6. Imagen SAR Calibrada y Recortada.

Para la corrección del moteado presente en la figura, se llevaron a cabo diferentes pruebas de multilooking y de filtrado. El mejor resultado se obtuvo al emplearse un filtro tipo “Lee Sigma”, con un numero de Look igual a la unidad, valor de sigma de 0.9 y tamaño de ventana de 3x3. El resultado se puede observar en la imagen de la figura 7.




Figura 7. Corrección del moteado de la imagen SAR.

Por último, se llevó a cabo la corrección geométrica de la imagen 7 empleando la herramienta Radar>>Geometric>>Terrain Correction>>Range-Doppler. El resultado se puede apreciar en la figura 8.




Figura 8. Imagen SAR corregida.

Adicionalmente, se tiene la posibilidad de visualizar la imagen en RGB, donde el valor de las tres bandas es resultado de la combinación de las bandas: Sigma0_VV y Sigma0_HH. Ver figura 9.




Figura 9. Vista de la imagen SAR en combinación RGB.

SELECCIÓN DE MUESTRAS

Para la selección de las muestras se empleó QuantumGIS para la visualización de la imagen SAR corregida, y con la ayuda de la herramienta de extracción ráster mediante extensión se extrae la ventana de visualización actual. En la figura 9,11 y

13 se pueden visualizar las imágenes de las principales clases de interés: agua, tierra y urbano. En las figuras 10, 12 y 13 se puede observar el análogo, pero sobre la imagen SAR.



Figura 10. Imagen de muestra que representa un río.




Figura 11. Muestra de un río sobre la imagen SAR.



Figura 12. Imagen de muestra para la clase tierra.




Figura 13. Muestra de la clase tierra sobre la imagen SAR.



Figura 14. Muestra de la clase urbano.




Figura 15. Muestra de la clase urbano sobre la imagen SAR.

SEGMENTACIÓN Y EXTRACCIÓN DE CARACTERÍSTICAS

Se implementó la aplicación con la estructura de mostrada en la figura 4. Posteriormente se llevó a cabo la extracción de las características de cada una de las clases seleccionadas en el paso anterior. En la figura 16, se puede apreciar el resultado de ejecutar una agrupación por crecimiento de región sobre la clase 1 que corresponde a la categoría cuerpo de agua.



Figura 16. Segmentación por el método Crecimiento por Región.

En la figura 17, se puede apreciar el resultado obtenido al ejecutar el método del codo para determinar el número de centroide óptimo. Este parámetro permite definir con mayor seguridad el número de clúster deseado para la segmentación de k medias. Por ultimo en la figura 18 se visualiza la venta de configuración del tipo de intersección que se va llevar a cabo con las tres regiones generadas a partir de los métodos de segmentación disponible.

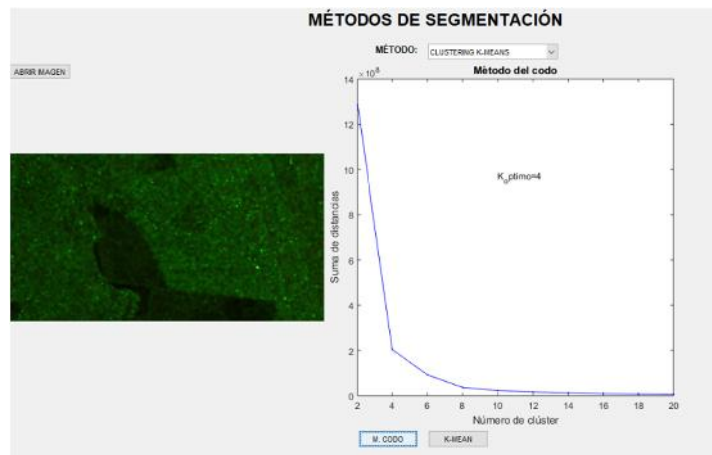


Figura 17. Método del codo para determinar el número óptimo de clúster.

[1] seleccionar [0] No seleccionar

Segmentación Crecimiento por región:
0

Segmentación K media:
1

Segmentación Manual:
1

OK Cancel

Figura 18. Ventana de configuración de la intersección.

Una vez concluida la intersección se tiene una matriz binaria con valor 1 aquellos pixeles que cumplen la condición definida en la ventana de la figura 18. Dicha matriz es convertida en formato de tabla y exportado a un archivo “.csv” con la estructura mostrada en la figura 19. La base de datos completa y sus respectivas particiones se adjuntan con el proyecto. Para el proceso de entrenamiento se emplearon las columnas C, D, y E. Como variable respuesta y categórica se empleó la columna F.

A	B	C	D	E	F	
Coord_X	Coord_Y	I_R	I_G	I_B	Clase	
1	33	0	6	0	1	
1	34	0	4	0	1	
1	35	1	3	0	1	
1	36	1	3	0	1	
1	37	2	2	2	1	
1	38	2	2	2	1	
1	39	3	1	4	1	
1	40	3	1	4	1	
1	41	2	2	2	1	
1	42	2	2	2	1	

Figura 19. Exportación de características de los pixeles de interés a un archivo csv.

CLASIFICACIÓN Y VALIDACIÓN DEL MODELO

Empleando el módulo classification learner de MATLAB 2016a se llevó a cabo el entrenamiento de los modelos (Bagged Forest y SVM Gaussian Fine) con las tres particiones propuestas 500, 1000 y 3000 muestras por cada clase. Hay que destacar que para cada clase se llevó a cabo una selección aleatoria de las muestras, es decir la muestras de 500 no necesariamente están incluidas en las muestras de 1000. Los resultados de la precisión empleando una validación cruzada de 5 sub grupos se muestra en la siguiente tabla.

Modelo	No Muestras	Muestras por clase	Validación cruzada, grupos	Precisión
B. Forest	1500	500	5	83.7%
SVM G.F.	1500	500	5	86.9%
B. Forest	3000	1000	5	85.6%
SVM G.F.	3000	1000	5	88.1%
B. Forest	9000	3000	5	85.8%
SVM G.F.	9000	3000	5	87.8%

Como se puede apreciar en la tabla la precisión de los dos modelos sobre cualquier partición del conjunto de entrenamiento es por arriba del 85%, se puede concluir anticipadamente que el comportamiento de los dos clasificadores es aceptable. Por otra parte, se empleó la herramienta de validación cruzada, que consiste en definir cinco subgrupos de datos y en cada iteración reserva 1/5 para obtener un porcentaje de validación y el resto 4/5 del conjunto de datos la emplea para entrenar el modelo. Hay aplicar este enfoque de validación cruzada se asegura que no existen problemas de sobre ajuste. Visualizando el comportamiento de los dos modelos se puede apreciar que el modelo SVM es superior al modelo Bagged Forest para todas las particiones del conjunto de datos. Analizados individualmente el modelo Bagged Foresto tuvo el mejor rendimiento cuando se corrió con la base de datos de 9000 muestras. Por su parte el modelo SVM Gaussian Fine obtuvo la mayor precisión cuando se entrenó con la base de datos de 3000 muestras. Este último es mejor de todos los modelos analizados con una precisión del 88.1%, es por ello que se emplea para analizar la matriz de confusión.

MATRIZ DE CONFUSIÓN

La matriz de confusión, también llamada tabla de contingencia, es una herramienta que nos muestra el desempeño de un algoritmo de clasificación, describiendo cómo se distribuyen los valores reales y nuestras predicciones.

En un modelo de clasificación en tres clases es posible calcular la precisión como la suma de valores positivos clasificados correctamente dividido entre el total de observaciones. La tasa del error viene dada por la diferencia entre la unidad y el porcentaje decimal de la precisión.

Se puede de igual forma calcular la sensibilidad, especificidad, valor predictivo positivo (VPP) y valor predictivo negativo (VPN) para cada clase. En la figura 20 se puede observar de manera gráfica la definición de estos índices.

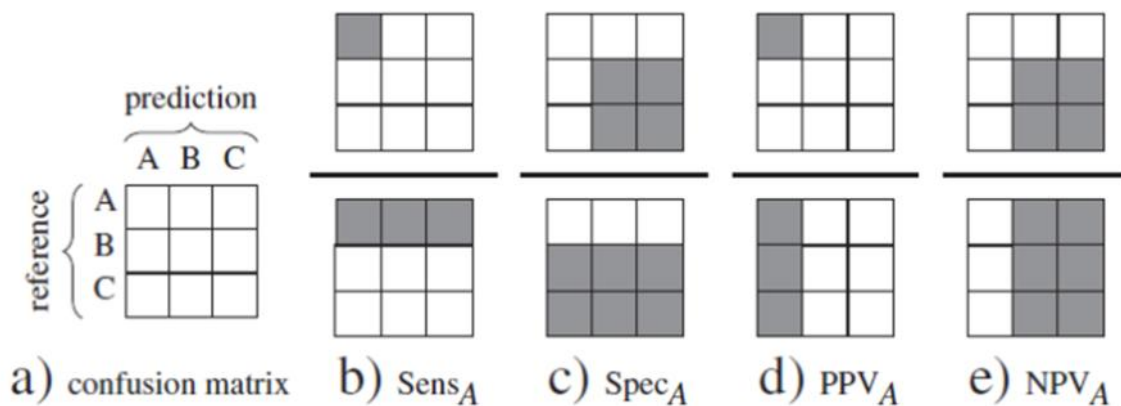


Figura 20. Cálculo de índices en una matriz de confusión multiclase.

Las definiciones de precisión (también conocido como valor predictivo positivo PPV) y recall (también conocido como sensibilidad), se relacionan con una clase independiente de cualquier otra clase:

El recall o sensibilidad es la proporción de casos correctamente identificados como pertenecientes a la clase c entre todos los casos que realmente pertenecen a la clase c. Por ejemplo, si se tiene un caso que realmente pertenece a "c", la sensibilidad responde a ¿cuál es la probabilidad de predecir esto correctamente?

Precisión o valor predictivo positivo PPV es la proporción de casos correctamente identificados como pertenecientes a la clase c entre todos los casos de los que el clasificador afirma que pertenecen a la clase c. En otras palabras, de los casos que se predice que pertenecen a la clase c, ¿qué fracción pertenece realmente a la clase c?, por ejemplo, dada la predicción "c", ¿cuál es la probabilidad de ser correcta?

El valor predictivo negativo VPN se refiere a los casos que se predice que no pertenecen a la clase c, ¿qué fracción realmente no pertenece a la clase c? por ejemplo, dada la predicción "no c", ¿cuál es la probabilidad de ser correcta?

En la figura 21 se puede apreciar la matriz de confusión para el modelo SVM Gaussian Fine sobre la base de datos de 3000 muestras. Obteniendo la suma de las diagonales y dividir entre la cantidad total de muestras se obtiene la precisión general del modelo equivalente a 88.1%, es decir tiene el 11.9 % de error al clasificar un nuevo conjunto de datos.




Figura 21. Matriz de confusión para el modelo SVM Gaussian Fine.

Debido a que se tiene una clasificación multiclase, a partir de la matriz de confusión se pueden calcular índices fijando una característica con la finalidad de ver el comportamiento del clasificador respecto a cada clase.

En la siguiente tabla se puede observar la sensibilidad SVM es del 100%, es decir sobre el conjunto de prueba que son con certeza son “Agua” las clasifica correctamente en su totalidad. La especificidad SVM es del 100%, es decir del conjunto de prueba que con certeza se sabe que no son “Agua”, las clasifica al 100%. El Valor Predictivo positivo SVM es del 100%, es decir cuando se llevaba a cabo una predicción sobre un conjunto de prueba desconocida se tiene la certeza que va clasificar al 100% la clase “Agua”. El valor predictivo negativo ANN es del 100%, es decir si se lleva a cabo la predicción sobre un nuevo conjunto de datos se tiene la certeza que se van a clasificar correctamente las clases que no son “Agua” en un 100% de los casos. En resumen, el clasificador frente al grupo de entrenamiento o una base de datos completamente ajena al modelo va clasificar correctamente la clase “Agua”, tanto positivos como negativos, es por ello que esta propuesta de clasificador resuelve totalmente el problema de detectar áreas inundadas en una imagen SAR.

Modelo	clase Agua			
	Sensibilidad	Especificidad	Valor predictivo positivo	Valor Predictivo Negativo
SVM GF	1.000	1.000	1.000	1.000

En la siguiente tabla se puede observar que para la clase “Tierra” la sensibilidad SVM es del 94.6%, es decir sobre el conjunto de entrenamiento que son con certeza son “Tierra” las clasifica de manera aceptable en un 94.6%. La especificidad SVM es del 84.9%, es decir del conjunto de entrenamiento que con certeza se sabe que no son variedad “Tierra”, las clasifica bien en 84.9% de los casos. El Valor Predictivo positivo SVM es del 75.7%, es decir cuando se llevaba a cabo una predicción sobre un conjunto de prueba desconocida se tiene la certeza que va clasificar bien la clase “Tierra” en un 75.7% que es un porcentaje relativamente bajo. El valor predictivo negativo SVM es del 96.9%, es decir si se lleva a cabo la predicción sobre un nuevo conjunto de datos, se tiene la certeza que se van a clasificar correctamente las clases que no son “Tierra” en un 96.9% de los casos. Se puede apreciar que para la clase “Tierra” durante el entrenamiento el modelo tiene un buen rendimiento, pero a la hora llevar a cabo una predicción el rendimiento es bajo y por consecuencia se puede tener una mala clasificación para esta clase.

Modelo	clase Tierra			
	Sensibilidad	Especificidad	Valor predictivo positivo	Valor Predictivo Negativo
SVM GF	0.946	0.849	0.757	0.969

En la siguiente tabla se puede observar que para la clase “Urbano” la sensibilidad SVM es del 69.7%, es decir sobre el conjunto de entrenamiento que son con certeza son “Urbano” las clasifica muy mal. La especificidad SVM es del 97.3%, es decir del conjunto de entrenamiento que con certeza se sabe que no son “Urbano”, las clasifica bien en 97.3% de los casos. El Valor Predictivo positivo SVM es del 92.8%, es decir cuando se llevaba a cabo una predicción sobre un conjunto de prueba desconocida se tiene la certeza que va clasificar bien la clase “Urbano” en un 92.8% que es un porcentaje bastante aceptable. El valor predictivo negativo SVM es del 86.5%, es decir si se lleva a cabo la predicción sobre un nuevo conjunto de datos, se tiene la certeza que se van a clasificar correctamente las clases que no son “Urbano” en un 86.5% de los casos. Se puede apreciar que para la clase “Urbano” el modelo tiene problemas para clasificar desde el entrenamiento y es por ello que a la hora de ejecutar una predicción los resultados pueden ser clasificados incorrectamente.

Modelo	Clase Urbano			
	Sensibilidad	Especificidad	Valor predictivo positivo	Valor Predictivo Negativo
SVM GF	0.697	0.973	0.928	0.865

PREDICCIÓN

Para llevar a cabo la predicción se parte de una imagen SAR convertida a formato jpg, y se arma una tabla con número de filas igual a la cantidad de pixeles que integran la imagen de entrada. Dicha tabla tiene tres columnas en las que se sitúan los valores de intensidad para las tres bandas: Rojo, Verde y Azul. La tabla anterior se envía al modelo SVM Gaussian Fine entrenado como parámetro y se recoge en una tabla de salida con una columna en la que se especifica la categoría resultante de la clasificación de cada tripleta RGB enviada. Con la tabla de resultados se arma nuevamente la matriz con la dimensión de la imagen de entrada, esta nueva matriz tendrá almacenada las etiquetas para cada pixel en la posición (x, y) de la imagen. En figura 22 se puede observar un ejemplo de clasificación de una imagen completamente ajena al modelo. Se puede apreciar que para la clase “Agua” la clasificación es muy buena, pero para las clases “Tierra” y “Urbano” existe mucha confusión y el desempeño es muy malo.

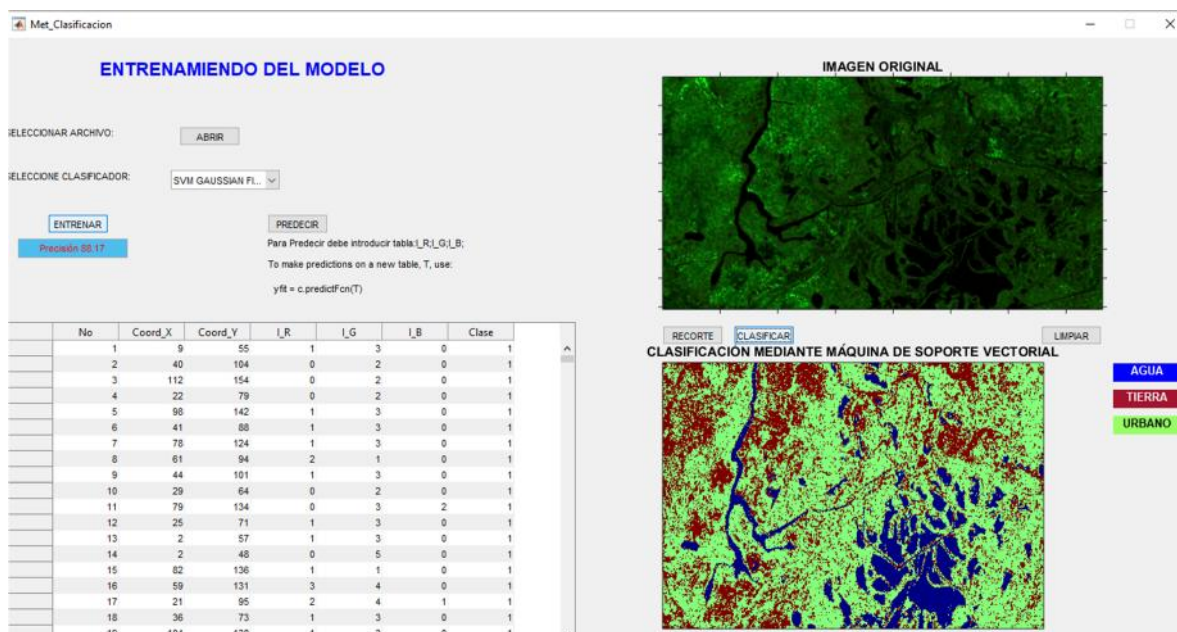


Figura 22. Ejemplo de clasificación del modelo SVM Gaussian entrenado.

CONCLUSIÓN

Se presentó una metodología bastante sencilla y apoyado de las herramientas del software open source SNAP para llevar a cabo el pre procesamiento de una imagen de radar de apertura sintética para su posterior análisis. Se desarrolló un algoritmo con interfaz gráfica bastante flexible para extraer regiones de una imagen con similitud de intensidad y con el método de K-Medias se incorporó de manera satisfactoria el algoritmo que permite sugerir un valor de clúster óptimo. Por otra parte, se analizaron dos modelos de aprendizaje automático supervisado obteniendo resultados muy alentadores para distinguir la clase agua del resto. Aunque para las clases tierra y urbano no se obtuvieron buenos resultados, es completamente posible mejorar la base de datos con características que sean capaz de diferenciar entre las dos clases y entrenar los modelos con la aplicación desarrollada con posibilidad de llevar a cabo predicciones y visualizaciones graficas de la clasificación resultante. En general el proyecto con objetivo académico sirvió bastante para reforzar conceptos vistos durante el curso y permitió una visualización del cómo tratar de dar solución a un problema real. Por último, es necesario resaltar que el presente proyecto es con fines académicos, para un trabajo de investigación es necesario la integración del trabajo en campo y la evaluación del rendimiento de los modelos con otros parámetros más rigurosos.

BIBLIOGRAFÍA

Adams, R. and L. Bischof. 1994. "Seeded región growing," Pattern Analysis and Machine Intelligence, IEEE Transactions on. vol. 16, no. 6, pp. 641–647.

Avendaño P., J., J.A. Parra P., y J. Fredy B. 2014. Segmentación y clasificación de imágenes SAR en zonas de inundación en Colombia, una herramienta computacional para prevención de desastres. Vol. 4, No. 8 pp 24-38. ISSN 2145-0935.

Dass R., P. and S. Devi, 2012. "Image segmentation techniques," International Journal of Electronics & Communication Technology IJEC. vol. 3, no. 14. pp. 66–70.

Ghosh S., y S. Kumar D. 2013. Comparative Analysis of K-Means and Fuzzy C-Means Algorithms. International Journal of Advanced Computer Science and Applications. Vol. 4, No.4.

MacQueen, B. 1967. "Some methods for classification and analysis of multivariate observations," in Proc. of the fifth Berkeley Symposium on Mathematical Statistics and Probability, L. M. L. Cam and J. Neyman, Eds., vol. 1, Proc. of the fifth Berkeley Symposium on Mathematical Statistics and Probability. University of California Press. pp. 281–297.